

1 Osnove

1.1 Kaj je umetna inteligenca?

- **cilji:** Razumeti in zgraditi inteligentne sisteme na osnovi razumevanja cloveskega *razmisljanja, sklepanja, učenja in komuniciranja*.

2 Strojno Učenje

2.1 Kaj je strojno učenje?

Je *področje umetne inteligence*, ki raziskuje kako se lahko algoritmi samodejno izboljšujejo ob pridobivanju izkušenj.

2.2 Vrste učenja:

- **Nadzorovano učenje** *supervised learning*: Učni primeri so označeni in podani kot vrednosti vhodov in izhodov. Učimo se funkcije, ki vhode preslika v izhode. (npr. odločitveno drevo)
- **Nenadzorovano učenje** *unsupervised learning*: Učni primeri niso označeni \rightarrow nimajo ciljne spremenljivke. Učimo se iz vzorcev v podatkih. (npr. grucenje)
- **Spodbujevalno učenje** *reinforcement learning*: Inteligentni agen se uči iz zaporedja nagrad in kazni.

2.3 Nadzorovano učenje

Podano imamo množico **učnih** primerov:

$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$$

kjer je vsak y_j vrednost neznane funkcije $y = f(x)$. Nasa naloga je posikati hipotetično funkcijo h , ki je najboljši možen približek funkciji f .

Locimo dve vrsti problemov:

1. **Klasifikacijski:** y_j je *diskretna(kategoricna)* spremenljivka
 - y pripada **koncnemu naboru vrednosti** (diskretna spremenljivka)
 - y imenujemo **razred** (class)
2. **Regresijski:** y_j je *zvezna* spremenljivka
 - y je stevilo (obicačno $y \in R$, je zvezna spremenljivka)
 - y imenujemo **oznacba** (label)

2.3.1 Prostor in evalviranje hipotez

Denimo da imamo:

- binarno klasifikacijo
- n binarnih atributov

Iz tega sledi:

- 2^n različnih učnih primerov
- 2^{2^n} hipotez (celotno odločitveno drevo)

Pomembni kriteriji pri *evalviranju* hipotez:

- **konsistentnost** hipotez s (učnimi) primeri
- **splosnost** točnost za nevidene primere
- **razumljivost** (*interpretability, comprehensibility*) hipotez

Poznamo 4 razrede za ocenjevanje uspešnosti pri klasifikaciji na podlagi njihove **točnosti**:

- **TP** - pravilno pozitivno klasificirani primeri
- **TN** - pravilno negativno klasificirani primeri
- **FP** - napacno pozitivno klasificirani primeri
- **FN** - napacno negativno klasificirani primeri

Klasifikacijska točnost je potem definirana:

$$CA = \frac{TP+TN}{TP+TN+FP+FN} = \frac{TP+TN}{N}$$

2.3.2 Odločitveno drevo

Ponazarja relacijo med vhodnimi *vrednostmi/atributi* in *odločitvojo/ciljno* spremenljivko.

Z **notranjimi vozlišci** opravljamo test glede na vrednost posameznega atributa. Na koncu pridemo do **lista**, ki nam s poroci odločitev (vrednost ciljne spremenljivke). Konjunkcijo pogojev v *notranjih vozlišcih* katera vodi do *lista* imenujemo **pot**.

Gradnja odločitvenega drevesa: Nas cilj je zgraditi **cim manjše drevo**, ki je **konsistentno** z učnimi podatki.

Hevristicni pozreznis algoritem - TDIDT s strategijo **razveji in omeji**:

- Izberi najbolj pomemben atribut - tisti, ki najbolj odločilno vpliva na klasifikacijo primera in razdeli primere v poddrevesa glede na njegove vrednosti
- rekurzivno ponovi za vsa drevesa
- ce vsi elementi v listu pripadajo istemu razredu ali vozlišca ni možno deliti naprej(ni razpoložljivih atributov), ustavi gradnjo

2.3.3 Izbor najbolj pomembnega atributa in informacijski prispevek

Najboljši atribut je tisti, ki razdeli učno množico v najbolj čiste podmnožice. Uporabimo lahko mero entropije:

$$H(X) = \sum_{i=1}^n p_i I_i = - \sum_{i=1}^n p_i \log_2 p_i$$

Zanima nas **znizanje** entropije (*nedolocenosti*) ob delitvi učne množice glede na vrednosti atributa A.

Definirajmo **informacijski prispevek** na takšen način, da najbolj informativni atribut **maksimizira informacijski prispevek** oz. minimizira I_{res} .

$$Gain(A) = I - I_{res}(A) \\ I_{res} = - \sum_{v_i \in A} p_{v_i} \sum_c p(c|v_i) \log_2 p(c|v_i)$$

2.3.4 Vecvrednostni atributi

Tezava z atributi, ki imajo več kot dve vrednosti: Informacijski prispevek preceňuje njihovo kakovost(entropija je visja na račun večjega števila vrednosti in ne na račun kakovosti atributa) resitve:

- normalizacija informacijskega prispevka: **relativni informacijski prispevek** ali IGR (information gain ratio)

$$Gain(a) = I - I_{res}(A), I(A) = - \sum_v p_v \log_2 p_v \\ GainRatio(A) = \frac{Gain(A)}{I(A)} = \frac{I - I_{res}(A)}{I(A)}$$

- uporaba **alternativnih mer**: npr. **Gini index** *Ocena pričakovane klasifikacijske napake, vsota produktov verjetnosti razredov*

$$Gini = \sum_{c1 \neq c2} p(c_1)p(c_2) \\ Gini(A) = \sum_v p(v) \sum_{c1 \neq c2} p(c_1|v)p(c_2|v)$$

- **binarizacija** atributov